

گزارش جامع پروژه مبانی بینایی کامپیوتر: اسکن و بهبود کیفیت اسناد

محمد امین حاجی علیرضایی، 40216623

۲۱ مرداد ۱۴۰۵

فهرست مطالب

۲	بخش اول: معماری شبکه‌های عصبی (CNN Architectures)
۲	بخش دوم: مهندسی داده‌ها و حل چالش‌های سیستمی
۳	بخش سوم: توابع زیان و استراتژی تنظیم (Regularization & Losses)
۳	بخش چهارم: سیر تکامل مدل‌ها (Evolution & Champions)
۴	بخش پنجم: آموزش یکپارچه (End-to-End Joint Training)
۴	بخش ششم: منطق سیستمیک، الگوریتم Ensemble و رابط کاربری
۵	نتیجه‌گیری

این گزارش، مستندات کامل مهندسی، معماری، چالش‌ها و سیر تکامل خطلوله (Pipeline) طراحی شده برای پروژه اسکن اسناد را از فاز صفر تا استقرار در رابط کاربری نهایی (Production) شرح می‌دهد. هدف اصلی این پروژه تبدیل عکس‌های خام و تخریب‌شده‌ی گوشی‌های هوشمند به اسکن‌های تمیز، تخت و با کیفیت بالا است. این سیستم از دو وظیفه اصلی تشکیل شده است: تشخیص گوشه‌ها (Corner Detection) و بهبود کیفیت (Document Enhancement).

بخش اول: معماری شبکه‌های عصبی (CNN Architectures)

پروژه بر پایه شبکه‌های عصبی پیچشی کاملاً سفارشی (بدون استفاده از وزن‌های از پیش آموزش دیده) پیاده‌سازی شده است. تمامی معماری‌ها در فایل `model.py` پیاده‌سازی شده‌اند.

- مدل بهبود کیفیت (Enhancement U-Net): یک معماری Encoder-Decoder مبتنی بر U-Net است که شامل ارتباطات میان‌بر (Skip Connections) برای حفظ جزئیات ظریف متن می‌شود. این شبکه دارای حدود 31 میلیون پارامتر قابل آموزش بوده و ورودی/خروجی آن تصاویری با رزولوشن 512×512 و 3 کانال رنگی (RGB) هستند.
- تشخیص گوشه رویکرد الف (Corner Regression): یک شبکه استخراج ویژگی (CNN Extractor) که به یک هد تمام‌متصل (Fully Connected) ختم می‌شود. این مدل 8 عدد (مختصات x و y برای 4 گوشه) خروجی می‌دهد و حدود 14.5 میلیون پارامتر دارد. به دلیل استفاده از لایه Flatten، این شبکه درک فضایی دوبعدی را از دست داده و دقت پایینی (MLE حدود 68.2 پیکسل) ثبت کرد.
- تشخیص گوشه رویکرد ب (Corner Heatmap): معماری پیروز و قهرمان پروژه. این مدل با استفاده از یک بون U-Net چهار نقشه حرارتی (Heatmap) گاوسی برای هر گوشه تولید می‌کند. برای استخراج دقیق و مشتق‌پذیر مختصات، از لایه SoftArgmax2D با دمای دوگانه (Dual-Temperature) استفاده شد ($\beta = 300$ در آموزش و $\beta = 10000$ در استنتاج برای حذف اعداد اعشاری غیردقیق).

بخش دوم: مهندسی داده‌ها و حل چالش‌های سیستمی

- آموزش این شبکه‌ها بر پایه داده‌های مصنوعی صورت گرفت.
۱. مشخصات مجموعه داده و تفکیک (Data Splits): مجموعه داده شامل 50 اسکن تمیز (Clean Scans) به عنوان هدف، و تصاویر پس‌زمینه تصادفی برای تولید محیط‌های شبیه‌سازی شده است. تفکیک داده‌ها با نرخ استاندارد 80/10/10 انجام شد. برای ارزیابی نهایی خطلوله در محیط واقعی، از 23 عکس خام گوشی هوشمند همراه با مشخصات ثبت شده در JSON و تصاویر معادل اسکن شده توسط CamScanner استفاده گردید.
 ۲. خطلوله تولید داده مصنوعی (Synthetic Pipeline): در کلاس `SyntheticDocumentDataset`، اسکن‌های تمیز روی پس‌زمینه‌های تصادفی قرار داده می‌شوند. 4 نقطه تصادفی روی پس‌زمینه انتخاب شده و اسکن با استفاده از ماتریس Homography و تابع `cv2.warpPerspective` روی آن‌ها Warp می‌شود. این 4 نقطه به صورت خودکار برچسب‌های دقیق گوشه را تشکیل می‌دهند.
 ۳. تخریب‌های ساختاری و نوری (Degradations): انواع تخریب‌ها با استفاده از OpenCV در فایل `degradation.py` پیاده‌سازی شدند. این موارد شامل: Motion & Gaussian Blur، نویز سنسور، فشرده‌سازی JPEG، تغییرات روشنایی/کنتراست و دمای رنگ می‌شود.
 ۴. رفع چالش‌های بحرانی داده‌ها (Dataset Bugs):

- حل مشکل Dataset Poisoning: تابع `_add_adjacent_page` به اشتباه خطوط سیاه ضخیمی را روی متن رسم می‌کرد. با افزودن عملگر Dot Product و بررسی بردار نرمال نسبت به مرکز سند، این مشکل هندسی حل شد.

- انحنای سه‌بعدی و تزریق گرافیک: برای جلوگیری از پاک شدن عناصر رنگی توسط مدل، تزریق کلاژهای گرافیکی و شبیه‌سازی `_apply_cylindrical_warp` (شبیه‌سازی انحنای شیرازه کتاب با تابع سینوسی) به خط‌لوله اضافه شدند.

۵. رفع قفل سیستم (Windows IPC Deadlock):

افزایش رزولوشن آموزش باعث OOM و IPC Deadlock در سیستم عامل ویندوز شد. این مشکل ناشی از تداخل Thread های OpenCV و PyTorch DataLoader بود. راه حل، غیرفعال‌سازی کامل تردینگ OpenCV با فرمان `cv2.setNumThreads(0)` بود.

بخش سوم: توابع زیان و استراتژی تنظیم (Regularization & Losses)

ترکیب توابع زیان بهبود کیفیت (Enhancement Loss):

برای جلوگیری از تولید عکس‌های تار، توابع زیان مهندسی شدند.

- استفاده از Smooth L1 Loss با ضریب `text_weight=5.0` برای تنبیه شدید مدل در صورت محو کردن جوهر تیره.

- استفاده از Sobel Edge Loss با وزن 2.0 برای مجبور کردن شبکه به حفظ وضوح لبه‌های حروف.

- استفاده از Cosine Similarity برای حفظ رنگ‌ها (`color_weight=2.0`).

کشف معمای Dropout (The Dropout Fallacy):

اعمال Global Dropout در تمام لایه‌های شبکه‌های استخراج مختصات فضایی منجر به فروپاشی هندسی (Geometric Collapse) می‌شود.

- راه حل (Scheduled Bottleneck Dropout): کلاس DropoutScheduler تنها لایه‌های عمیق (Bottleneck) را هدف قرار داد. با اعمال یک Warm-up پنج اپوکی، Dropout توانست به عنوان یک Semantic Regularizer قدرتمند عمل کند.

بخش چهارم: سیر تکامل مدل‌ها (Evolution & Champions)

با ارزیابی مستمر، مدل‌های نهایی در سه سطح دسته‌بندی شدند.

۱. قهرمانان تشخیص گوشه (Corner Detection):

- مدل طلا (`heatmap_v4_reg`): آموزش دیده با Scheduled Dropout و داده‌های V4. ثبت کمترین خطای ممکن (MLE برابر با 14.97 پیکسل).

- مدل نقره (`heatmap_v3`): بدون Dropout. یادگیری کاملاً Data-Centric. خطای MLE معادل 35.04 پیکسل.

۲. قهرمانان بهبود کیفیت (Enhancement U-Net):

- مدل طلا (`enh_regularized_v2`): بالاترین درصد موفقیت OCR (56.90%). استفاده از Dropout باعث تعمیم فرم هندسی حروف شد.

- مدل نقره (`enh_clean_v2`): بالاترین درستی پیکسلی و ریاضی با PSNR معادل 21.54 دسی‌بل و SSIM معادل 0.8544.

بخش پنجم: آموزش یکپارچه (End-to-End Joint Training)

برای بهینه‌سازی نهایی خط‌لوله، شبکه تشخیص گوشه و شبکه Enhancement به صورت End-to-End آموزش دیدند. این فرآیند سیگنال خط را از خروجی نهایی U-Net به شبکه‌ی گوشه‌یاب منتقل می‌کند.

۱. فرمول‌بندی مشتق‌پذیر (Differentiable Flow):

ارتباط بین دو شبکه از طریق ماتریس Homography برقرار شد. برای حفظ پیوستگی گرادیان‌ها در طول Backpropagation، از تابع warp_perspective در کتابخانه Kornia استفاده شد که امکان عبور گرادیان از فرآیند برش عکس را فراهم می‌کند.

۲. چالش‌های آموزش و Selective AMP:

به دلیل سنگینی همزمان دو شبکه، استفاده از Float16 (AMP) ضروری بود. با این حال، محاسبه مشتق تابع Sobel Loss روی پیکسل‌های تاریک باعث تولید مقادیری فراتر از آستانه Float16 (بروز Gradient Explosion و NaN Loss) می‌شد. این مشکل با پیاده‌سازی Selective AMP رفع شد؛ به گونه‌ای که شبکه‌ها در Float16 اجرا شده، اما محاسبات هندسی Kornia و تابع زیان در Float32 انجام شدند.

۳. نتایج و پارادوکس تاری (Blurriness Paradox):

آموزش یکپارچه نتایج متناقض اما از نظر علمی ارزشمندی به همراه داشت:

- بهبود هندسی: خطای گوشه‌یاب از 14.97 به 13.19 پیکسل کاهش یافت (MLE) و به دقیق‌ترین مدل پروژه تبدیل شد.

- افت کیفیت Enhancement: در مقابل، کیفیت خروجی تنزل یافت (PSNR به 19.84 دسی‌بل و OCR به 40.11% افت کرد). این پدیده به دو دلیل رخ داد: اول، تکنیک Bilinear Interpolation در Kornia مانند یک فیلتر پایین‌گذر عمل کرده و لبه‌ها را نرم می‌کند. دوم، تله‌ی Spatial Misalignment Trap؛ از آنجا که گوشه‌های پیش‌بینی شده در این مرحله همچنان 1 الی 2 پیکسل خطا دارند، شبکه U-Net برای فرار از جریمه‌های سنگین تابع زیان (ناشی از عدم تطابق کامل پیکسل‌های جوهر با هدف)، یاد می‌گیرد که متن را به صورت عمدی تار (Blur) تولید کند.

بخش ششم: منطق سیستمیک، الگوریتم Ensemble و رابط کاربری

به دلیل ماهیت متناقض نتایج در فاز End-to-End، معماری سیستم به صورت ماژولار (Decoupled) حفظ شد.

۱. الگوریتم Ensemble هوشمند نسخه ۰.۳:

مدل طلایی، نقره‌ای، برنزی و مدل جدید E2E Finetuned در این مرحله به عنوان رأی‌دهندگان هندسی وارد عمل می‌شوند. برای جلوگیری از "Reward Hacking"، سیستم ۸۱ ترکیب موجود را با قوانینی مانند تقارن پرسپکتیو، محدودیت زوایای داخلی، و نسبت اعوجاج اضلاع روبه‌رو فیلتر می‌کند تا بهترین مستطیل را از بین خروجی مدل‌ها استخراج کند.

۲. دروازه‌بان‌های آماری تصاویر خارج از توزیع (OOD Gatekeepers):


- Gatekeeper A (Corner Bypass): بررسی واریانس و یکدستی روشنایی در حاشیه 3 درصدی تصویر برای تشخیص تصاویر از پیش کراپ‌شده.

- Gatekeeper C (Enhancement Bypass): تحلیل هیستوگرام تصویر برای تشخیص اسکن‌های دیجیتال و جلوگیری از اعوجاج در عکس‌های بدون نویز.

۳. استقرار در رابط کاربری (UI Strategy):

- کاربر می‌تواند در بخش تشخیص گوشه از مدل ترکیبی (Smart Ensemble) استفاده کند که شامل وزن‌های ارتقایافته‌ی فاز E2E است. در بخش Enhancement نیز، کاربر مدل قهرمان مستقل (enh_regularized_v2) را انتخاب می‌کند تا بدون درگیر شدن با خطاهای Interpolation، بالاترین سطح کیفیت بازتولید شود.

- امکان بارگذاری فایل‌های چندصفحه‌ای PDF از طریق PyMuPDF تعبیه شده که هر صفحه را پردازش کرده و مجدداً ترکیب می‌کند.



شکل ۱: رابط کاربری (UI) سیستم در حالت‌های تشخیص خودکار و ویرایشگر تعاملی

نتیجه‌گیری

این پروژه با موفقیت یک خط‌لوله End-to-End پایدار را پیاده‌سازی کرد. ترکیب داده‌های مهندسی‌شده، توابع زیان تخصصی، کشف رفتار Dropout در مختصات فضایی و اعمال استراتژی‌های Ensemble و Gatekeepers ثابت کرد که مدل‌های CNN در کنار منطق و فیلترهای کلاسیک، توانایی رقابت مستقیم با محصولات اسکن تجاری را دارا هستند.